Experimentación reproducible con MLflow

TC5061 | José Andrés Hernández Guerra | A01840564
11 de octubre de 2026

Análisis de resultados

Se migró el baseline Titanic del notebook a un script parametrizado de regresión logística. Se evaluaron seis configuraciones y una réplica bajo el mismo experimento, con 891 pasajeros, siete variables predictoras y una división estratificada 80/20 (712 para entrenamiento y 179 para evaluación). Se fijó la semilla 42 y el umbral de clasificación 0.5. La comparación de MLflow permitió contrastar los parámetros y métricas de todas las corridas.

Se eligió F1 de la clase sobreviviente como criterio antes de comparar, por el desequilibrio de clases (549 no sobrevivientes y 342 sobrevivientes). La mejor configuración fue C=1, class_weight=balanced, solver=lbfgs y max_iter=1000: F1=0.7552, accuracy=0.8045 y ROC-AUC=0.8462. Frente a la base (F1=0.7244), el recall subió de 0.6667 a 0.7826, mientras la precision bajó de 0.7931 a 0.7297. El ganador recuperó 54 de los 69 sobrevivientes, con 20 falsos positivos y 15 falsos negativos. C=10 obtuvo la mayor accuracy (0.8101) y C=0.1 el mayor ROC-AUC (0.8469); la selección depende de la métrica priorizada.

C fue el hiperparámetro más influyente dentro de los valores probados: su variación entre 0.01, 0.1, 1 y 10 cambió F1 de 0.6286 a 0.7344 (rango 0.1058). C=0.01, con regularización más fuerte, redujo el recall a 0.4783. El balanceo de clases mejoró F1 en 0.0308 respecto a la base; cambiar a liblinear no cambió F1 ni accuracy. Se modificó un hiperparámetro a la vez, por lo que no se evaluaron sus interacciones ni puede extrapolarse esta influencia a otros rangos.

La réplica produjo métricas, predicciones y partición idénticas. Se corrigió la filtración del notebook: el percentil 99 de Fare se aprende solo con entrenamiento, junto con la imputación, escalado y codificación. Se registraron el pipeline completo, dependencias, huella del dataset y commit del código; el ganador quedó en Model Registry, versión 1, alias candidate. Las principales limitaciones son el dataset pequeño, una única partición y el uso de esa misma evaluación para seleccionar y reportar el ganador. Las métricas no estiman de forma independiente su generalización. El siguiente paso sería validar con particiones cruzadas y reservar una prueba final separada.

Ejecución y trazabilidad

Repositorio GitHub pendiente de publicación. Antes de entregar, regenerar este documento con el enlace real mediante **build_report.py --repo-url**.

Entorno utilizado: Python 3.14.7, MLflow 3.17.0, scikit-learn 1.9.1, NumPy 2.5.4, pandas 3.0.6 y matplotlib 3.11.2. Dependencias directas en requirements.txt y entorno completo en requirements-lock.txt.

Comandos exactos desde la raíz del proyecto

python run_experiments.py
python train.py --C 1.0 --class-weight balanced
--solver lbfgs --seed 42 --run-name 05_balanced

El comando de entrenamiento anterior se escribe en una sola línea. Sin argumentos, **python train.py** ejecuta la base. results/commands.txt conserva los siete comandos ejecutados.

Interfaz: mlflow ui --backend-store-uri sqlite:///mlflow.db
--host 127.0.0.1 --port 5000
Abrir http://127.0.0.1:5000 y seleccionar el experimento TC5061-Titanic-Experimentacion-Logistica.

Resumen de las corridas registradas

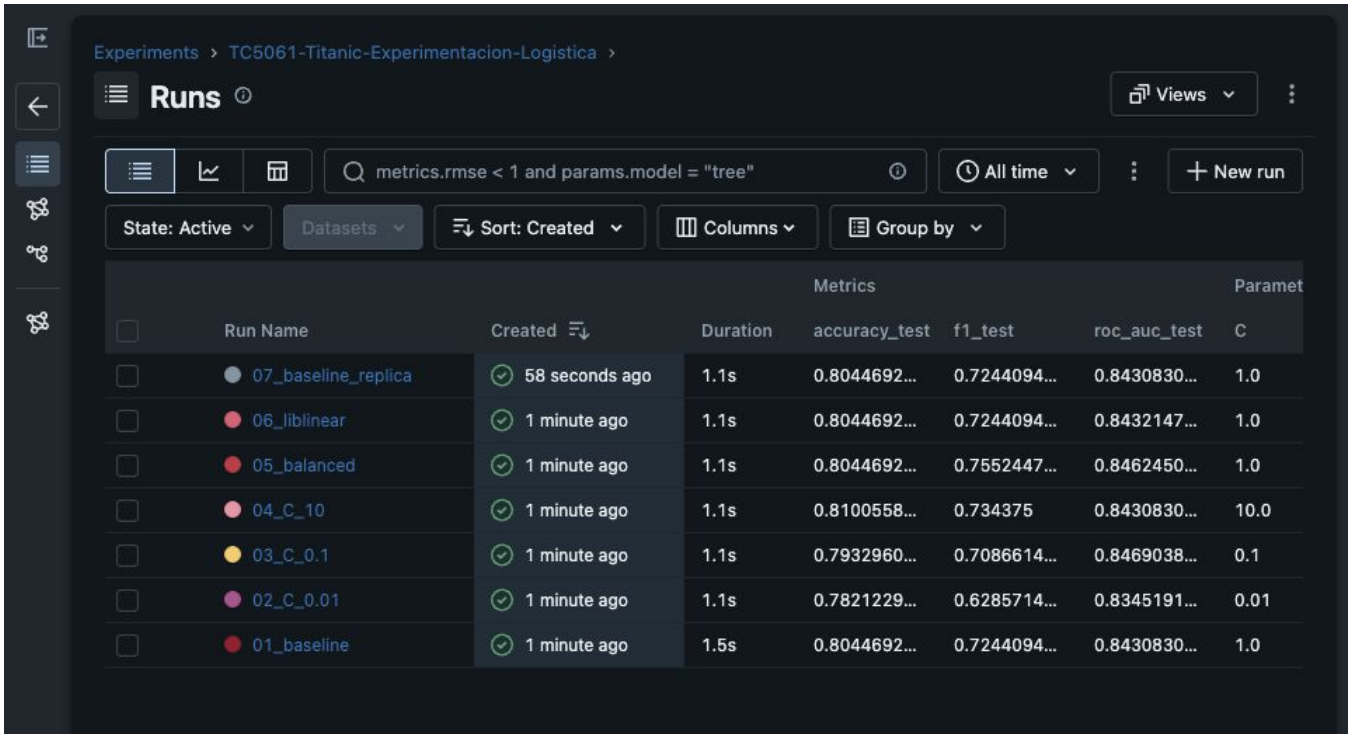
Corrida	C	Peso	Solver	Acc.	F1	AUC
01_baseline	1	none	lbfgs	0.8045	0.7244	0.8431
02_C_0.01	0.01	none	lbfgs	0.7821	0.6286	0.8345
03_C_0.1	0.1	none	lbfgs	0.7933	0.7087	0.8469
04_C_10	10	none	lbfgs	0.8101	0.7344	0.8431
05_balanced	1	balanced	lbfgs	0.8045	0.7552	0.8462
06_liblinear	1	none	liblinear	0.8045	0.7244	0.8432
07_réplica base	1	none	lbfgs	0.8045	0.7244	0.8431

La comparación excluye la réplica para seleccionar el ganador. La verificación de reproducibilidad y recarga está en results/reproducibility.json. Commit de entrenamiento: f05df9f1db72. Cada corrida guarda SHA-256 de código y datos.

Referencias: MLflow sklearn; scikit-learn LogisticRegression.

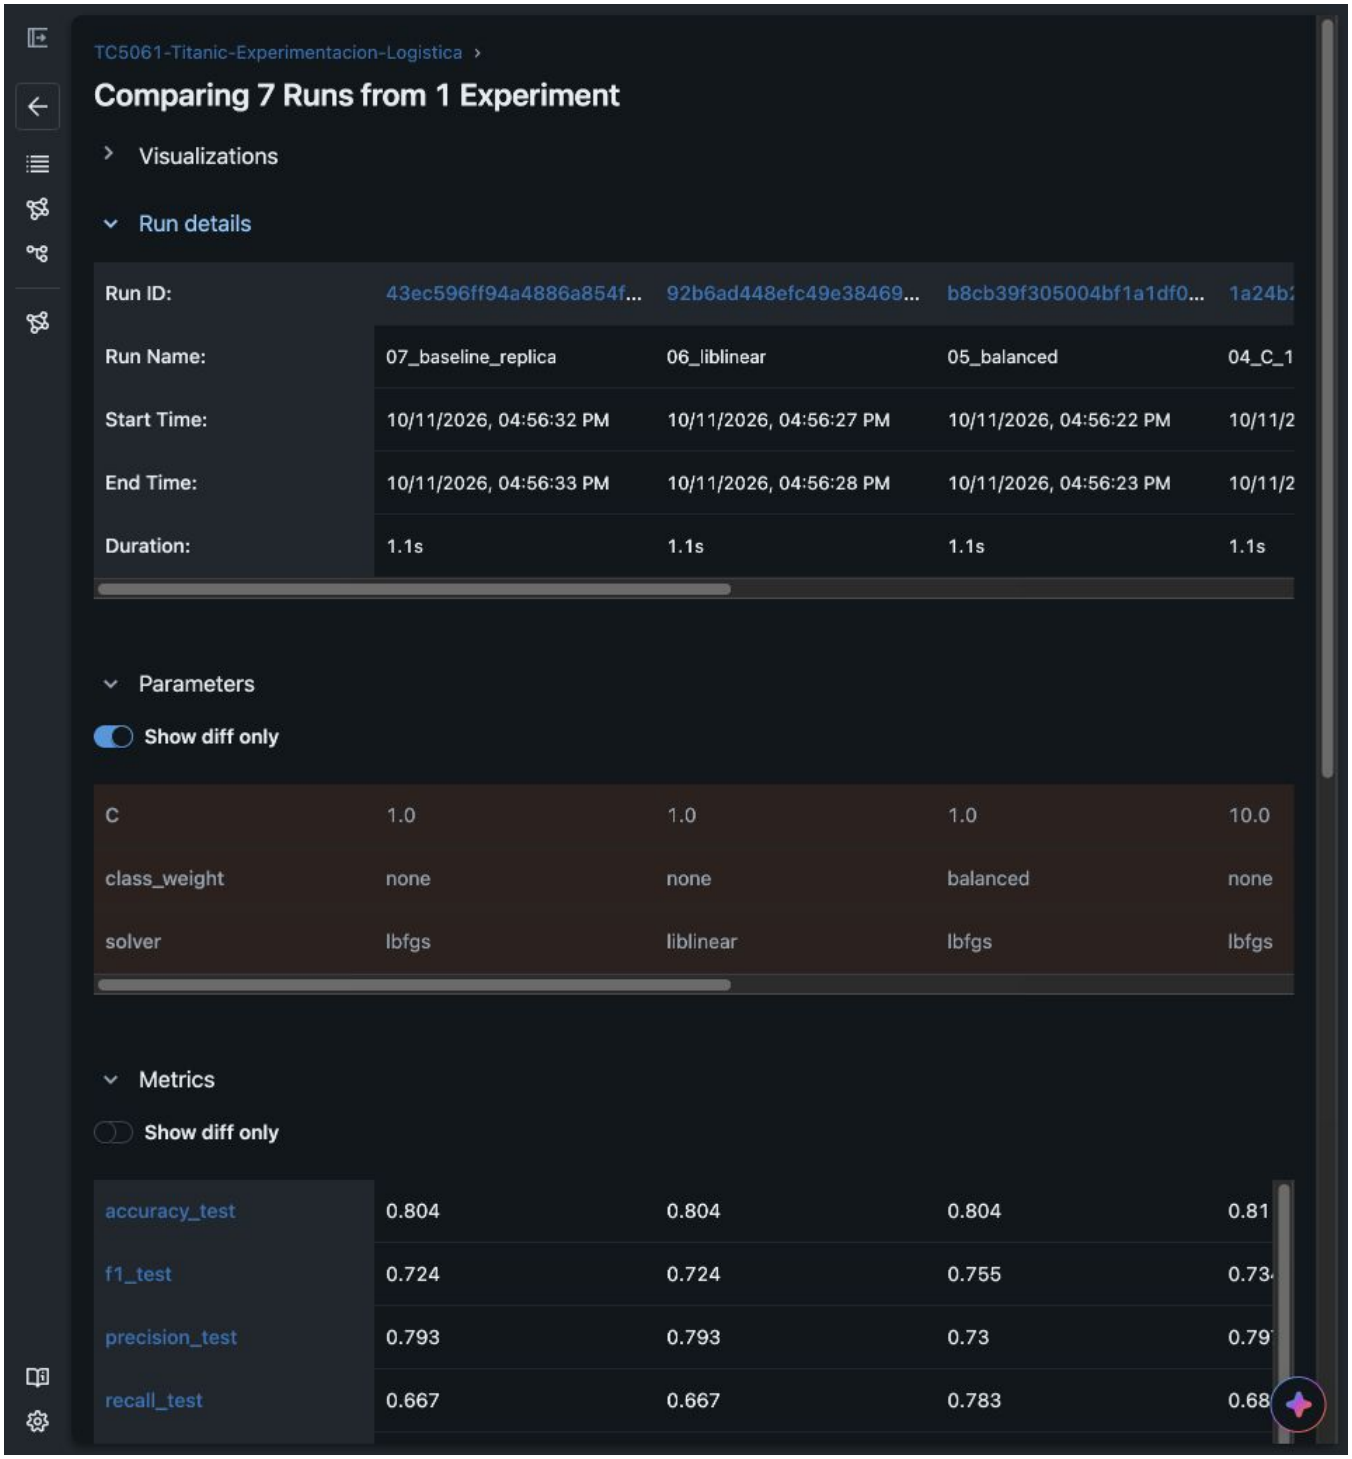
Evidencia 1 - Tabla de corridas

Captura real de MLflow: siete corridas del mismo experimento. Se muestran accuracy, F1, ROC-AUC y C.



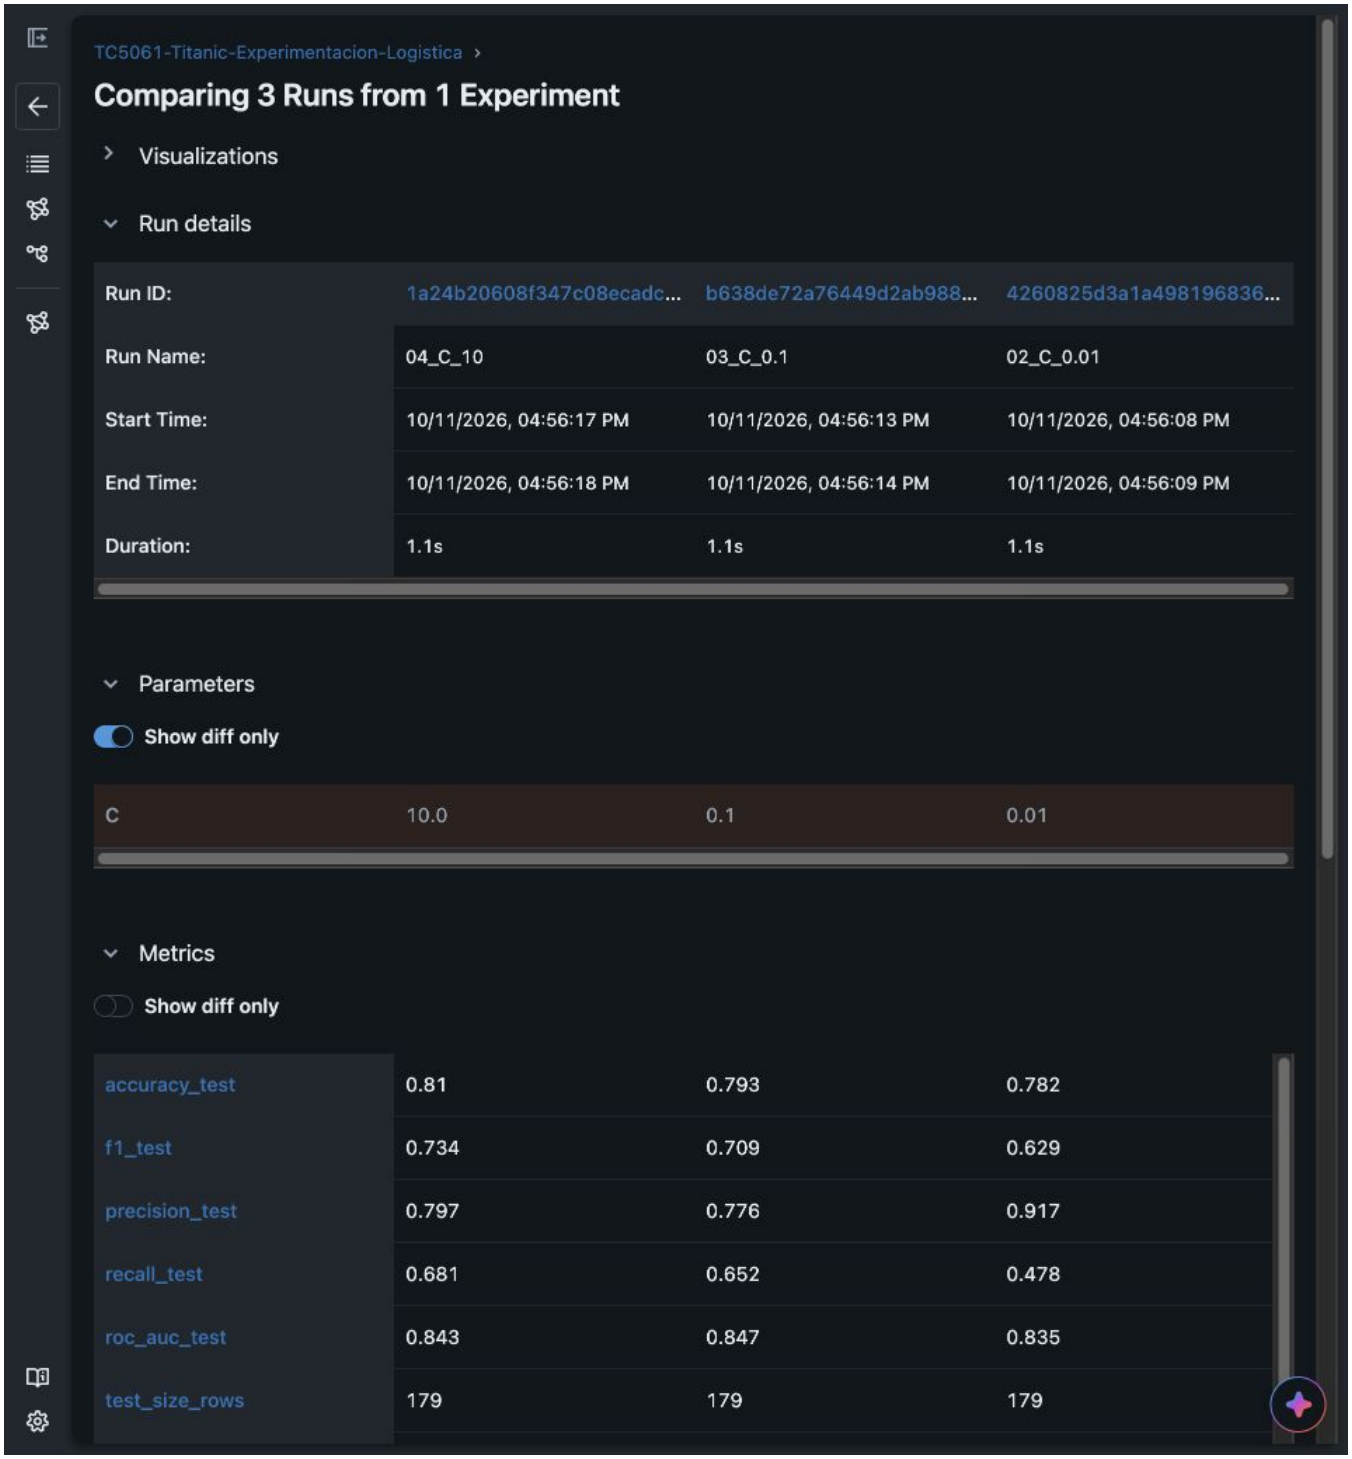
Evidencia 2 - Vista de comparación

Compare Runs con siete corridas seleccionadas. Primera parte de la vista horizontal: réplica, liblinear y balanced. F1 fundamenta la selección.



Evidencia 2 - Influencia de C

Comparación complementaria de C=10, C=0.1 y C=0.01, manteniendo los demás parámetros. El resumen de las siete corridas aparece en la página 2.



Evidencia 3 - Detalle y artefactos

Corrida ganadora 05_balanced, ID b8cb39f305004bf1a1df0c6a5b8fed1f. Artifacts contiene la evaluación, matriz de confusión y procedencia; el pipeline completo se guarda en Models.

